

LAPORAN ANALISIS: Scraping dan EDA Data Atletik Olimpiade Paris 2024

Nama: Bima Satriawan

NRP: 5054251031

Tugas: Scraping dan EDA

1. Deskripsi Dataset

Dataset diperoleh melalui *web scraping* halaman Wikipedia "Athletics at the 2024 Summer Olympics". Proses scraping dilakukan menggunakan library *requests* untuk mengambil HTML, *BeautifulSoup* untuk parsing, dan *pandas* untuk menyusun data ke bentuk tabular.

Dari halaman utama, berhasil diidentifikasi 48 URL halaman cabang olahraga atletik (misalnya Men's 100 metres, Women's 800 metres, Men's High Jump). Setiap halaman kemudian di-scrape untuk mengekstraksi tabel hasil pertandingan.

Hasil akhir dataset:

PROPERTI	NILAI
Jumlah baris	1.625 Data
Jumlah kolom	8
Cakupan event	20 cabang lari dan gawang (track and hurdles)
Cakupan negara	171 negara
Jumlah atlet unik	849 atlet

Atribut dataset:

KOLOM	TIPE
event_url	Nominal
round	Ordinal (Heat-Semifinal-Final)
Rank	Ordinal (Juara 1=terbaik)
Lane	Nominal
Athlete	Nominal
Nation	Nominal

Result	Numerik kontinu (dalam detik atau format MM:SS)
Notes	Nominal

Data mentah disimpan ke data/olympics_raw.csv sebelum diproses lebih lanjut, sesuai ketentuan tugas.

2. Statistik Deskriptif

- Atribut Numerik

Statistik pada Lane (hanya relevan untuk sprint dan hurdles yang menggunakan lintasan):

STATISTIK	NILAI
Count	903
Mean	5.28
Median	5.00
Standar Deviasi	2.32
Min	1
Max	9

Distribusi Lane mendekati merata ($\text{mean} \approx \text{median} \approx 5$), menunjukkan hasil yang konsisten dan seimbang di olimpiade ini.

- Atribut Kategorikal

- Distribusi ronde:

RONDE	FREKUENSI
Heat	1.224
Final	233
Semifinal	168

Heat mendominasi karena setiap atlet berlomba di babak penyisihan, sedangkan perbandingan yang menjomplang antara semifinal dengan final dikarenakan beberapa event yang diselenggarakan tidak melalui babak semifinal.

NEGARA	JUMLAH ENTRY
United States	133
Great Britain	79
Jamaica	66
France	66
Kenya	64
Australia	60
Canada	57
Italy	57
Ethiopia	51
Spain	45

Amerika Serikat mendominasi hingga hampir dua kali lipat dari Great Britain. Konsisten dengan jumlah populasi atletik Amerika yang besar dan program pembinaan yang kuat.

- Disrtibusi Notes (penanda catatan khusus):

NOTES	FREKUENSI
(kosong)	903
Q (qualified by place)	375
PB (Personal best)	82
SB (Season best)	73
NR (National record)	35
q (qualified by time)	34

Sebanyak 55.6% baris tidak memiliki catatan khusus, artinya mayoritas atlet tidak lolos dan tidak mencetak Personal best, Season best, ataupun National record dalam penampilan mereka.

3. Penanganan Data

- Nilai hilang(missing value):

KOLOM	JUMLAH HILANG	PRESENTASE	PENYEBAB
Rank	102	6.3%	DNS (Did Not Start)/DQ (Disqualified) /DNF (Did Not Finish)
Lane	722	44.4%	Hanya event sprint yang memiliki Lane
Result	1	0.06%	DNS (Did Not Start)
Notes	903	55.6%	Mayoritas atlet tidak punya catatan khusus

Keputusan:

- *missing value* pada kolom Lane bersifat struktural, yang di mana event sprint saja yang memiliki Lane, dengan begitu sengaja dibiarkan (NaN). Karena jika mengisi data hilangnya akan menjadi data palsu.
- Nilai hilang pada Rank dibiarkan karena terkait langsung dengan status atlet (DNS/DQ/DNF)

- Inkonsistensi Format

A. Penamaan ronde: Ditemukan penamaan yang tidak konsisten untuk ronde semifinal, sebagian halaman menggunakan "Semifinal" dan sebagian lainnya "Semi-final". Kedua label disatukan menjadi "Semifinal" untuk konsistensi analisis.

B. Format Result: Kolom Result memiliki setidaknya 3 format numerik berbeda:

- Detik desimal (misal: 10.29) untuk sprint
- MM:SS.ss (misal: 2:01.60) untuk lari jarak menengah
- Penanda non-numerik: DNS, DQ, DNF

Karena analisis difokuskan pada struktur dataset (bukan perbandingan waktu antar-event), format ini didokumentasikan saja.

- Keterbatasan Scraping

Beberapa event (relay, field events, decathlon, heptathlon) menggunakan skema tabel yang berbeda dan tidak berhasil diekstraksi. Selain itu, tabel Final untuk Women's 100 metres hurdles mengandung kolom tambahan Reaction sehingga tidak tertangkap oleh parser. Keterbatasan ini didokumentasikan dan tidak mempengaruhi kesimpulan utama karena dataset yang berhasil dikumpulkan sudah mencukupi syarat minimum.

4. Visualisasi dan Interpretasi

- Grafik 1: Top 20 Negara Berdasarkan Kehadiran/Kemunculan Atlet

Amerika Serikat memimpin dengan 133 entry, disusul Great Britain (79), Jamaica (66), dan France (66). Distribusi ini menunjukkan bahwa negara-negara dengan populasi besar dan tradisi atletik kuat mendominasi partisipasi. Namun, terdapat juga negara-negara kecil seperti Jamaica dan Bahamas yang muncul di peringkat atas karena spesialisasi mereka di cabang sprint

- Grafik 2: Top 15 Negara Berdasarkan Penampilan di Final

Ketika difilter hanya ke babak Final, komposisi negara berubah. Negara-negara seperti Jamaica dan Kenya tetap muncul tinggi, menunjukkan kualitas atlet yang konsisten. Negara-negara yang muncul di grafik ini tetapi tidak terlalu tinggi di Grafik 1 menunjukkan "konversi partisipasi ke final" yang efisien, sedikit atlet tetapi berkualitas tinggi.

- Grafik 3: Struktur Event per Ronde (Heatmap)

Heatmap mengungkap pola struktural penting:

- Sprint dan hurdles (100m–400m) memiliki tiga ronde: Heat, Semifinal, Final.-
- Lari jarak menengah (800m, 1500m, 5000m, steeplechase) hanya memiliki Heat dan Final, tidak ada Semifinal.
- 10.000m hanya memiliki Final (tidak ada babak penyisihan).

Perbedaan ini mencerminkan keputusan organisasi Olimpiade berdasarkan jumlah peserta dan durasi setiap cabang. Satu sel kosong (Women's 100m

hurdles Final) merupakan keterbatasan scraping, bukan data yang benar-benar tidak ada.

- Grafik 4: Hubungan Antara Lane dan Rank (Event Sprint)

Boxplot menunjukkan pola U-shape:

- Median rank terbaik ada di lane tengah (4, 5, 6) dengan median rank 4.
- Median rank terburuk ada di lane pinggir (1, 2, 8, 9) dengan median rank 5–6.
- Lane 1 menunjukkan variabilitas terbesar (box paling lebar).

Pola ini konsisten dengan teori atletik bahwa lane tengah memberikan keuntungan karena kelengkungan lintasan yang lebih seimbang. Namun, korelasi tidak berarti kausalitas lane di babak Final diberikan berdasarkan performa di babak sebelumnya, sehingga atlet tercepat cenderung mendapat lane tengah.

5. Kesimpulan

Dataset hasil scraping berhasil memenuhi syarat minimum tugas (1.625 baris × 8 kolom). Analisis struktur mengungkapkan:

1. Dominasi Amerika Serikat dalam partisipasi atletik, hampir dua kali negara berikutnya.
2. Perbedaan struktural antara sprint (3 ronde) dan lari jarak menengah (2 ronde atau kurang).
3. Pola halus antara lane dan rank pada event sprint, konsisten dengan teori keuntungan lane tengah.
4. Keterbatasan scraping yang teridentifikasi: beberapa event menggunakan skema tabel berbeda, dan satu event kehilangan data Final karena kolom tambahan.

